


在本階段的實作中，我們將傳統的 Q-Learning 升級為 Deep Q-Network (DQN)，以神經網路取代 Q-Table 來逼近 Q-value 函數，解決狀態空間過大時表格無法負荷的問題。

1. **Basic DQN 架構設計：** 模型使用了包含三層 Fully Connected Layers 的神經網路（節點數為 100 -> 150 -> 100 -> 4）。輸入為 Gridworld 展開為一維的狀態陣列（1x100），輸出則為對應上下左右（u, d, l, r）四個方向的 Q-value。

2. **Experience Replay Buffer (經驗回放池)：**

- **運作原理：**代理人（Agent）在環境中探索時，將每一步的經驗 (state, action, reward, next\_state, done) 存入一個容量有限的 Deque 中。在本次實作中，Buffer 容量設定為 1000。訓練時，系統會隨機從中抽取 Minibatch（設定 batch size = 200）來進行神經網路的反向傳播。
- **為何需要此機制：**強化學習中連續的狀態（State）之間具有高度關聯性。如果讓神經網路按照時間順序學習，容易導致訓練不穩定甚至發散（Catastrophic Forgetting）。
- **機制成效：**透過隨機抽樣，成功打破了資料間的時序相關性，讓訓練過程如同在處理獨立同分布（i.i.d.）的資料，大幅提升了神經網路收斂的穩定度。

根據訓練過程記錄的 hw3-1\_metrics.png，我們可以觀察到模型在 1000 個 Epochs 下的優異表現：




### 1. Loss over Training Steps (損失函數收斂狀態)：

- 在訓練初期（前 1000 steps），由於代理人正在隨機探索環境且 Experience Replay 剛開始累積資料，預測的 Q-value 與實際 Target 差距較大，因此 Loss 呈現劇烈震盪且數值較高。
- 隨著訓練步數增加，代理人累積了足夠的成功與失敗經驗，神經網路的權重逐漸調整到位。在 4000 steps 之後，Loss 已經穩定收斂並趨近於 0，僅在探索到未見過的狀態時有極小幅度的波動，顯示模型已經非常穩定。

### 代理人路徑決策分析 (Path Analysis)

從 hw3-1\_path.jpg 的實際測試路徑可以看出 DQN 學習到的具體策略：



- **環境配置：**起點 (Start) 位於右上角 (0,3)，終點 (Goal) 位於左上角 (0,0)，而在起點與終點之間有著陷阱 (Pit, 0,1) 與牆壁 (Wall, 1,1) 的阻擋。

- **決策路徑**：代理人沒有選擇最短但具備高風險的直線路徑（因為會直接掉入陷阱），也沒有試圖穿越無法通過的牆壁。
- **閃避策略**：代理人選擇了「往下繞行」的策略。從 **Start** 出發後，先向左移動一格，接著向下連續移動兩格繞開 **Wall**，再向左移動兩格，最後向上移動抵達 **Goal**。
- **結論**：這條完美避開所有負面獎勵（**Pit**）與障礙物（**Wall**）的安全路徑，清楚地證明了模型不僅僅是記住了終點的位置，而是真正學會了根據環境中的 **Reward** 分佈（避開陷阱、尋找目標）來最大化其未來的長期回報（**Q-value**）。