

在 Player Mode 中，代理人的起始位置變為隨機，這大幅提升了環境的複雜度與難度。基本的 DQN 在此時容易遇到「過度估計 (Overestimation)」與「無效狀態學習」的問題。為了解決這些痛點，我們實作了 Double DQN 與 Dueling DQN。


1. Double DQN 改良機制 (解決過度估計)：

- **痛點：**Basic DQN 同時使用同一個網路進行「動作選擇」與「價值評估」，容易選到帶有正向雜訊的動作，導致 Q 值不斷膨脹。
- **解法：**Double DQN 引入了獨立的 Target Network，將動作的「選擇 (使用 Main Network)」與「評估 (使用 Target Network)」拆開。這有效緩解了過度估計的偏差，使得學到的 Q 值更貼近真實的長期回報。

2. Dueling DQN 改良機制 (提升學習效率)：

- **痛點：**在許多安全區域，選擇什麼動作並不重要，但 Basic DQN 仍必須精確計算所有 (state, action) 的 Q 值，浪費運算資源。
- **解法：**Dueling DQN 將網路在最後一層分流為評估「狀態好壞」的 Value Stream $V(s)$ ，以及評估「動作優勢」的 Advantage Stream $A(s, a)$ 。透過減去 Advantage 的平均值，模型能更有效地學習狀態本身的價值，在初始狀態多變的環境中能更快泛化並收斂。

根據訓練過程記錄的 hw3-2_comparison.png，我們對比了兩種改良模型的學習成效：




1. Win Rate over Epochs (勝率表現與收斂速度)：

- **早期適應力差異**：在前 100 個 epochs 中，Dueling DQN（紫色三角線）的初始勝率高達約 92%，顯著超越了 Double DQN（藍色方塊線）的 67%。這完美印證了 Dueling DQN 理論上的優勢：透過獨立學習狀態價值 $V(s)$ ，它在面對 Player Mode 這種隨機起始位置的環境時，具備更強大的早期泛化能力。
- **長期穩定度**：在經過 200 epochs 後，兩種模型都成功收斂，勝率皆穩定維持在近乎 100%，展現了它們在解決複雜環境下的強大能力。

2. Loss over Training Steps (損失函數平穩度)：

- 觀察 Loss 曲線，Double DQN 在訓練中段（1000~3000 steps）仍會出現多次反覆的波峰震盪。
- 相對而言，Dueling DQN 雖然在初期（約 1000 steps）有一次較顯著的震盪（因為神經網路分流正在建立特徵特化），但在經歷震盪後，其 Loss 曲線迅速貼近 0 且極度平滑。這顯示分離 Value 與 Advantage 確實增強了神經網路學習後期的穩定性。

觀察 hw3-2_paths_comparison.jpg 的實際測試路徑，我們驗證了模型在隨機起始點下的決策能力：



- **測試環境條件：**在本次隨機生成的測試中，起點被放置於最遠的右下角角落 (4,4) 位置。
- **策略高度一致：**面對相同的極端起點，Double DQN 與 Dueling DQN 展現出了不謀而合的最佳解策略。兩者皆選擇「先一路向左移動至最左側邊界，接著再一路向上」的 L 型路徑直達 Goal (0,0)。
- **結論：**這條路徑完美地避開了位於 (0,1) 的陷阱 (Pit) 與位於 (1,1) 的牆壁 (Wall)。這證明兩種改良模型不僅解決了起點隨機變化的干擾，而且都成功學會了全域的環境認知，能在任何未知的起點瞬間規劃出最安全、有效的通關路徑。